
Analyse de données d'établissements de santé

Exploration, analyse, SQL et visualisation des données

Réalisé par Hadjer BENAÏSSA

Formation Master 2 Statistique et Science des Données – SSD-MIND

Université Université de Montpellier

Outils Excel – SQL – Python – Pandas – Git/GitHub

Table des matières

1	Introduction	2
2	Présentation de la base de données	2
3	Préparation et contrôle des données	3
4	Méthodologie d'analyse sous Excel	4
5	Indicateurs clés de l'activité	4
6	Analyse graphique de l'activité	5
6.1	Évolution mensuelle du nombre de patients en 2026	5
6.2	Nombre de patients par type d'activité	6
6.3	Nombre de patients par établissement	6
6.4	Nombre de patients par département	7
7	Construction du tableau de bord	7
8	Structuration et analyse des données avec SQL	8
8.1	Création de la table	8
8.2	Automatisation de l'insertion des données avec Python	8
8.3	Insertion des données	9
8.4	Calcul des indicateurs avec SQL	10
8.5	Analyse par établissement	10
8.6	Analyse par type d'activité	11
8.7	Analyse territoriale	11
8.8	Analyse temporelle	11
9	Complémentarité des outils	12
10	Limites de l'analyse	12
11	Conclusion	13

1. Introduction

Dans le cadre de ma préparation à une recherche d'alternance en Master 2 Statistique et Science des Données, parcours Management de l'Information et de la Décision (SSD-MIND), j'ai réalisé un projet personnel d'analyse de données appliqué au secteur de la santé.

Ce projet repose sur une base de données entièrement fictive représentant l'activité de plusieurs établissements de santé.

L'objectif est de mettre en pratique une démarche complète d'analyse de données, depuis la structuration et l'exploitation de la base jusqu'à la création d'indicateurs et d'un tableau de bord d'aide à la décision.

Plusieurs outils ont été mobilisés au cours du projet :

- Excel pour l'analyse exploratoire et les tableaux croisés dynamiques ;
- SQL pour structurer et interroger les données ;
- Python et Pandas pour automatiser la génération des insertions SQL ;
- Excel pour construire les visualisations et le tableau de bord ;
- Git et GitHub pour organiser et versionner le projet.

Important : toutes les données utilisées dans ce projet sont entièrement fictives et ont été créées uniquement à des fins d'apprentissage et de démonstration.

2. Présentation de la base de données

La base utilisée contient des données fictives relatives à plusieurs établissements de santé situés dans différents départements.

Chaque ligne correspond à une observation associée à un établissement, une année, un mois et un type d'activité.

La base contient 288 observations.

Les principales variables utilisées sont les suivantes :

Variable	Description
ID	Identifiant unique de l'observation.
Établissement	Nom de l'établissement de santé concerné par l'observation.
Département	Numéro du département dans lequel se situe l'établissement.
Année	Année à laquelle les données d'activité correspondent.
Mois	Mois auquel les données d'activité correspondent.
Activité	Type d'activité médicale : chirurgie, maternité, médecine ou soins de réadaptation.
Nombre de patients	Volume de patients enregistré pour l'établissement, la période et le type d'activité concernés.
Nombre de séjours	Nombre total de séjours hospitaliers enregistrés pour l'établissement, la période et le type d'activité concernés.
Durée moyenne de séjour	Durée moyenne, exprimée en jours, des séjours enregistrés.

TABLE 1 – Description des principales variables de la base

Les six établissements présents dans la base sont :

- Clinique des Cèdres ;
- Clinique du Parc ;
- Clinique Nîmes Santé ;
- Clinique Perpignan Sud ;
- Clinique Saint-Roch ;
- Clinique Toulouse Centre.

Les quatre types d'activité étudiés sont :

- Chirurgie ;
- Maternité ;
- Médecine ;
- Soins de réadaptation.

3. Préparation et contrôle des données

Avant de commencer l'analyse, plusieurs contrôles ont été réalisés afin de vérifier la qualité et la cohérence du jeu de données.

Les principales vérifications ont porté sur :

- la recherche de doublons ;
- l'identification des valeurs manquantes ;

- la vérification des formats et des types de données ;
- la suppression des espaces inutiles ;
- le contrôle de la cohérence générale des valeurs.

Les fonctionnalités d'Excel et de Power Query ont également été explorées afin de mieux comprendre les possibilités de préparation et de transformation des données.

4. Méthodologie d'analyse sous Excel

L'analyse exploratoire a été réalisée principalement à l'aide de tableaux croisés dynamiques sous Excel. Cette méthode permet de regrouper rapidement les observations selon différentes dimensions et de calculer des indicateurs synthétiques.

Les principales dimensions étudiées sont :

- le temps, à travers les années et les mois ;
- les établissements ;
- les départements ;
- les types d'activité.

Les analyses ont ensuite été transformées en graphiques croisés dynamiques afin de faciliter l'interprétation des résultats.

5. Indicateurs clés de l'activité

Quatre indicateurs principaux ont été construits afin de fournir une vision synthétique du jeu de données.

Indicateur	Valeur
Total des patients	110 337
Total des séjours	81 183
Nombre d'établissements	6
Durée moyenne de séjour	5,64 jours

TABLE 2 – Principaux indicateurs du tableau de bord

Ces indicateurs permettent d'obtenir rapidement une vue d'ensemble de l'activité représentée dans la base fictive.

6. Analyse graphique de l'activité

Afin de compléter les indicateurs globaux, quatre visualisations principales ont été intégrées au tableau de bord.

6.1. Évolution mensuelle du nombre de patients en 2026

Le premier graphique permet d'étudier l'évolution du nombre de patients au cours des six premiers mois de l'année 2026.




FIGURE 1 – Évolution mensuelle du nombre de patients en 2026

Les résultats obtenus sont les suivants :

- mois 1 : 9 419 patients ;
- mois 2 : 9 986 patients ;
- mois 3 : 8 647 patients ;
- mois 4 : 9 969 patients ;
- mois 5 : 8 847 patients ;
- mois 6 : 8 903 patients.

L'activité reste globalement stable sur la période observée, avec des variations modérées d'un mois à l'autre.

Le mois 2 présente le volume le plus élevé avec 9 986 patients, tandis que le mois 3 enregistre le niveau le plus faible avec 8 647 patients.

Cette analyse permet d'identifier rapidement les périodes présentant une hausse ou une diminution de l'activité.

6.2. Nombre de patients par type d'activité

La deuxième analyse porte sur la répartition du nombre de patients selon le type d'activité médicale.




FIGURE 2 – Nombre de patients par type d'activité

La médecine représente le volume de patients le plus important avec 28 771 patients.

Elle est suivie de :

- la chirurgie avec 28 054 patients ;
- les soins de réadaptation avec 26 977 patients ;
- la maternité avec 26 535 patients.

Les écarts restent relativement limités entre les quatre catégories. La répartition de l'activité apparaît donc globalement équilibrée dans le jeu de données étudié.

6.3. Nombre de patients par établissement

La troisième analyse compare le volume total de patients entre les six établissements.




FIGURE 3 – Nombre de patients par établissement

La Clinique Perpignan Sud présente le volume de patients le plus important avec 19 977 patients.

Elle est suivie de la Clinique Saint-Roch avec 19 348 patients.

Les autres établissements enregistrent :

- Clinique Nîmes Santé : 18 487 patients ;
- Clinique du Parc : 18 252 patients ;
- Clinique des Cèdres : 17 716 patients ;
- Clinique Toulouse Centre : 16 557 patients.

Les différences observées restent modérées. Cette analyse permet néanmoins d'identifier rapidement les établissements présentant les volumes d'activité les plus importants.

6.4. Nombre de patients par département

Une analyse territoriale a également été réalisée afin de comparer le volume de patients selon le département.




FIGURE 4 – Nombre de patients par département

Le département 34 présente le volume de patients le plus important avec 37 600 patients.

Il est suivi du département 31 avec 34 273 patients.

Les départements 66 et 30 enregistrent respectivement 19 977 et 18 487 patients.

Ces résultats doivent toutefois être interprétés en tenant compte du nombre d'établissements représentés dans chaque département. Un département regroupant plusieurs établissements peut naturellement présenter un volume global plus élevé.

7. Construction du tableau de bord

Les différents indicateurs et graphiques ont été regroupés dans un tableau de bord Excel afin de fournir une vue synthétique de l'activité des établissements.

Le tableau de bord comprend :

- quatre indicateurs clés ;

- l'évolution mensuelle du nombre de patients ;
- la comparaison du nombre de patients par établissement ;
- la répartition du nombre de patients par type d'activité ;
- la comparaison du nombre de patients par département ;
- des filtres permettant d'explorer les résultats selon différentes dimensions.

L'objectif du tableau de bord est de rendre les résultats rapidement lisibles et de faciliter l'identification des principales tendances du jeu de données.

8. Structuration et analyse des données avec SQL

Afin de compléter l'analyse réalisée sous Excel, une partie SQL a été intégrée au projet.

L'objectif est de structurer les données dans une table et d'utiliser des requêtes pour calculer les principaux indicateurs et réaliser différentes analyses.

8.1. Création de la table

La première étape consiste à définir la structure de la table `cliniques`.

Chaque variable du jeu de données est associée à un type adapté.

Listing 1 – Création de la table cliniques

```
1 CREATE TABLE cliniques (  
2     id INT PRIMARY KEY,  
3     etablissement VARCHAR(100),  
4     departement INT,  
5     annee INT,  
6     mois INT,  
7     activite VARCHAR(100),  
8     nombre_patients INT,  
9     nombre_sejours INT,  
10    duree_moyenne_sejour DECIMAL(5,2)  
11 );
```

La clé primaire `id` permet d'identifier de manière unique chaque observation.

Les variables textuelles sont stockées sous forme de `VARCHAR`, les variables numériques entières sous forme de `INT` et la durée moyenne de séjour sous forme de `DECIMAL`.

8.2. Automatisation de l'insertion des données avec Python

Le jeu de données contenant 288 observations, la rédaction manuelle des instructions SQL d'insertion aurait été longue et répétitive.

Un script Python utilisant la bibliothèque `Pandas` a donc été développé afin d'automatiser cette étape.

Le script réalise les opérations suivantes :

1. lecture automatique du fichier `Data.ods` ;
2. adaptation des noms de colonnes aux noms utilisés dans la table SQL ;
3. parcours des 288 observations ;
4. transformation de chaque observation au format SQL ;
5. génération automatique du fichier `02_insertion_donnees.sql`.

Le processus peut être résumé de la manière suivante :

Data.ods $\rightarrow$ Python/Pandas $\rightarrow$ 02_insertion_donnees.sql

Cette automatisation améliore la reproductibilité du projet. En cas de modification du fichier source, le script peut être exécuté à nouveau afin de générer automatiquement un nouveau fichier d'insertion.

8.3. Insertion des données

Les observations sont ensuite insérées dans la table `cliniques`.

La structure générale de l'insertion est la suivante :

Listing 2 – Exemple d'insertion des données

```
1 INSERT INTO cliniques (  
2     id,  
3     etablissement,  
4     departement,  
5     annee,  
6     mois,  
7     activite,  
8     nombre_patients,  
9     nombre_sejours,  
10    duree_moyenne_sejour  
11 )  
12 VALUES  
13 (1, 'Clinique Saint-Roch', 34, 2025, 1,  
14 'Medecine', 194, 100, 7.40);
```

Le fichier complet contient les instructions permettant d'insérer automatiquement les 288 observations du jeu de données.

8.4. Calcul des indicateurs avec SQL

Plusieurs requêtes ont été développées afin de reproduire les principaux indicateurs utilisés dans le tableau de bord.

Nombre total de patients

```
1 SELECT
2     SUM(nombre_patients) AS total_patients
3 FROM cliniques;
```

La fonction SUM additionne les volumes de patients enregistrés dans les différentes observations.

Nombre total de séjours

```
1 SELECT
2     SUM(nombre_sejours) AS total_sejours
3 FROM cliniques;
```

Nombre d'établissements

```
1 SELECT
2     COUNT(DISTINCT etablissement)
3         AS nombre_etablissements
4 FROM cliniques;
```

La fonction COUNT associée à DISTINCT permet de compter uniquement les établissements différents.

Durée moyenne de séjour

```
1 SELECT
2     ROUND(AVG(duree_moyenne_sejour), 2)
3         AS duree_moyenne_sejour
4 FROM cliniques;
```

8.5. Analyse par établissement

La requête suivante permet de calculer le volume total de patients pour chaque établissement :

```
1 SELECT
2     etablissement,
3     SUM(nombre_patients) AS total_patients
4 FROM cliniques
5 GROUP BY etablissement
6 ORDER BY total_patients DESC;
```

La clause `GROUP BY` regroupe les observations appartenant au même établissement.

La fonction `SUM` calcule ensuite le volume total de patients pour chacun de ces groupes.

Enfin, `ORDER BY` permet de classer les établissements selon leur volume de patients.

8.6. Analyse par type d'activité

La même logique est utilisée pour analyser les données selon le type d'activité.

```
1 SELECT
2     activite ,
3     SUM(nombre_patients) AS total_patients
4 FROM cliniques
5 GROUP BY activite
6 ORDER BY total_patients DESC;
```

Cette requête permet de comparer les volumes de patients entre la médecine, la chirurgie, la maternité et les soins de réadaptation.

8.7. Analyse territoriale

La requête suivante permet d'étudier la répartition des patients selon le département :

```
1 SELECT
2     departement ,
3     SUM(nombre_patients) AS total_patients
4 FROM cliniques
5 GROUP BY departement
6 ORDER BY total_patients DESC;
```

8.8. Analyse temporelle

L'évolution mensuelle des patients pour l'année 2026 peut également être obtenue directement avec SQL.

```
1 SELECT
2     mois ,
3     SUM(nombre_patients) AS total_patients
4 FROM cliniques
5 WHERE annee = 2026
6 GROUP BY mois
7 ORDER BY mois;
```

La clause `WHERE` sélectionne uniquement les observations correspondant à l'année 2026.

La clause `GROUP BY` permet ensuite de calculer le nombre total de patients pour chaque mois.

Une analyse annuelle peut également être réalisée :

```

1 SELECT
2     annee ,
3     SUM(nombre_patients) AS total_patients
4 FROM cliniques
5 GROUP BY annee
6 ORDER BY annee;

```

9. Complémentarité des outils

Ce projet a permis de mobiliser plusieurs outils complémentaires dans une même démarche d'analyse de données.

Outil	Utilisation dans le projet
Excel	Exploration des données, tableaux croisés dynamiques, calcul des indicateurs, graphiques et construction du tableau de bord.
SQL	Structuration de la table, interrogation des données, agrégations, regroupements, filtres et analyses.
Python / Pandas	Lecture du fichier source et automatisation de la génération des 288 lignes d'insertion SQL.
Git / GitHub	Organisation, sauvegarde et versionnement des différents éléments du projet.
LaTeX	Rédaction et mise en forme du rapport d'analyse.

TABLE 3 – Outils mobilisés dans le projet

La démarche globale du projet peut être résumée de la manière suivante :

Données → Préparation → Python → SQL → Analyse Excel → Visualisation →
Tableau de bord

10. Limites de l'analyse

Plusieurs limites doivent être prises en compte dans l'interprétation des résultats.

Tout d'abord, les données utilisées sont entièrement fictives. Les résultats ne peuvent donc pas être interprétés comme représentant l'activité réelle des établissements mentionnés.

Par ailleurs, la variable `nombre_patients` représente un volume de patients associé à une observation. La base ne contient pas d'identifiant individuel permettant de suivre un patient entre plusieurs périodes ou plusieurs activités.

La somme du nombre de patients représente donc un volume cumulé d'activité et non nécessairement un nombre de patients uniques.

Enfin, certaines comparaisons territoriales doivent être interprétées en tenant compte du nombre d'établissements présents dans chaque département.

11. Conclusion

Ce projet personnel m'a permis de mettre en pratique plusieurs étapes d'une démarche d'analyse de données appliquée à un jeu de données fictif dans le domaine de la santé.

L'utilisation d'Excel a permis d'explorer les données, de construire des tableaux croisés dynamiques, de calculer des indicateurs et de réaliser un tableau de bord interactif.

L'intégration de SQL a permis de structurer les données et de reproduire plusieurs analyses à l'aide de requêtes d'agrégation, de regroupement, de filtrage et de tri.

Enfin, l'utilisation de Python et de Pandas a permis d'automatiser la génération des instructions SQL nécessaires à l'insertion des 288 observations.

Ce projet m'a ainsi permis de travailler sur une chaîne d'analyse combinant plusieurs compétences complémentaires : préparation des données, automatisation, SQL, analyse exploratoire, construction d'indicateurs et datavisualisation.

Dans une perspective d'approfondissement, ce travail pourrait être complété par la création d'un tableau de bord sous Power BI, l'intégration des données dans un véritable système de gestion de base de données et le développement d'analyses statistiques plus avancées.

Hadjer BENAÏSSA

Master 2 Statistique et Science des Données – SSD-MIND

Université de Montpellier